

ANALYSE EN COMPOSANTES PRINCIPALES

ACP

Galharret, J.-M.

L'ANALYSE DE DONNÉES

- L'analyse de données fait partie de la statistique multivariée.
- Elle est basée sur des méthodes géométriques et sur l'algèbre linéaire pour mettre en évidence sous forme graphique la structure sous-jacente des données.
- Elle comprend
 1. l'analyse en composantes principales (ACP) pour des données quantitatives, l'analyse factorielle des correspondances (AFC) pour des données qualitatives (tableaux de contingence) et l'analyse factorielle des correspondances multiples (ACM) qui est une généralisation de l'AFC.
 2. les méthodes de classifications dont l'objectif est de former des sous groupes homogènes au sein des individus considérés et des caractéristiques étudiées.

ANALYSE EN COMPOSANTE PRINCIPALE

Formalisée en 1930 par Hotelling. On considère un tableau de données quantitatives du type $X(N, P)$. Autrement dit on a N individus (lignes de X notées I_n) caractérisés par P variables (colonnes de X notées X_p).

But

- **Représenter les individus dans un espace de dimension $k < P$.**
- **Caractériser cette représentation relativement aux variables initiales.**

QUELQUES RAPPELS

$$X = \begin{pmatrix} x_{11} \cdots x_{1p} \cdots x_{1P} \\ \vdots \vdots \vdots \vdots \vdots \\ x_{n1} \cdots x_{np} \cdots x_{nP} \\ \vdots \vdots \vdots \vdots \vdots \\ x_{N1} \cdots x_{Np} \cdots x_{NP} \end{pmatrix}$$

$I_n \in \mathbb{R}^P$ N individus qui sont des éléments de $\mathbb{R}^P$

$X_p \in \mathbb{R}^N$ P variables qui sont des éléments de $\mathbb{R}^N$

$$d^2(I_n, I_{n'}) = \sum_{p=1}^P (x_{np} - x_{n'p})^2$$

$$\text{cov}(X_p, X_{p'}) = \frac{1}{N} \sum_{n=1}^N (x_{np} - \bar{x}_p)(x_{np'} - \bar{x}_{p'})$$

EXEMPLE

	Math	Phys	Fran	Angl
jean	9.1	11.1	10.7	15.1
alain	10.2	12.1	11.3	14.3
annie	11.6	13.2	13.6	15.6
monique	9.8	11.7	12.3	14.6
didier	11.2	12.2	13.5	14.9
andré	11.4	12.6	13.4	14.9
pierre	9.0	11.5	11.3	13.2
brigitte	10.9	12.9	12.2	12.4
évelyne	11.2	12.3	14.1	15.7

Donc : $X(9,4)$.

- Les individus sont des éléments d'un espace de dimension 4 (on ne peut pas les représenter !)
- Les variables sont des éléments d'un espace de dimension 9.

On peut calculer les moyennes/variances des élèves :

	M	VAR
jean	11.500	4.880000
alain	11.975	2.256875
annie	13.500	2.030000
monique	12.100	2.935000
didier	12.950	1.932500
andré	13.075	1.616875
pierre	11.250	2.232500
brigitte	12.100	0.545000
évelyne	13.325	2.951875

et les moyennes/variances des notes :

	M	VAR
Math	10.48889	0.8832099
Phys	12.17778	0.4017284
Fran	12.48889	1.3143210
Angl	14.52222	1.0528395


On peut calculer les moyennes/variances des élèves :

	M	VAR
jean	11.500	4.880000
alain	11.975	2.256875
annie	13.500	2.030000
monique	12.100	2.935000
didier	12.950	1.932500
andré	13.075	1.616875
pierre	11.250	2.232500
brigitte	12.100	0.545000
évelyne	13.325	2.951875

et les moyennes/variances des notes :

	M	VAR
Math	10.48889	0.8832099
Phys	12.17778	0.4017284
Fran	12.48889	1.3143210
Angl	14.52222	1.0528395

CORRÉLATIONS ENTRE LES NOTES



INDIVIDUS DANS $\mathbb{R}^P$

- Les N individus sont des éléments de $\mathbb{R}^P$. On parle de nuage de points.
- L'Inertie du nuage de points est définie par :

$$\mathcal{I} = \sum_{n=1}^N d^2(I_n, \bar{I}),$$

où $\bar{I}$ est l'individu moyen du nuage c'est à dire l'individu ayant pour coordonnées les moyennes des P variables $\bar{I} = (\bar{X}_1, \dots, \bar{X}_P)$.

CALCUL DE L'INERTIE

On a :

$$\begin{aligned}
 \mathcal{J} &= \sum_{n=1}^N d^2(I_n, \bar{I}) \\
 &= \sum_{n=1}^N \sum_{p=1}^P (x_{np} - \bar{X}_p)^2 \\
 &= \sum_{p=1}^P \text{var}(X_p)
 \end{aligned}$$
$$\begin{pmatrix}
 x_{11} - \bar{X}_1 & \cdots & x_{1p} - \bar{X}_p & \cdots & x_{1P} - \bar{X}_P \\
 \vdots & & \vdots & & \vdots \\
 x_{n1} - \bar{X}_1 & \cdots & x_{np} - \bar{X}_p & \cdots & x_{nP} - \bar{X}_P \\
 \vdots & & \vdots & & \vdots \\
 x_{N1} - \bar{X}_1 & \cdots & x_{Np} - \bar{X}_p & \cdots & x_{NP} - \bar{X}_P
 \end{pmatrix}$$

Donc l'inertie du nuage de points est égale à la somme des variances des P caractéristiques.

MATRICE DE COVARIANCE

- On centre la matrice X sur les colonnes, notée X^c
- La matrice carrée V de taille P définie par

$$V = \frac{1}{N} (X^c)^T \cdot X^c$$

est appelée la matrice de covariance de X .

- Les éléments diagonaux de V sont égaux aux variances $v_{pp} = \text{Var}(X_p)$. **La somme des éléments de la diagonale de V est égale à l'inertie du nuage.**
- Les éléments hors diagonale sont les covariances. L'élément à la ligne p et de la colonne p' est

$$v_{pp'} = \text{cov}(X_p, X_{p'}).$$

$$X^c = \begin{pmatrix} x_{11} - \bar{X}_1 & \cdots & x_{1p} - \bar{X}_p & \cdots & x_{1P} - \bar{X}_P \\ \vdots & & \vdots & & \vdots \\ x_{n1} - \bar{X}_1 & \cdots & x_{np} - \bar{X}_p & \cdots & x_{nP} - \bar{X}_P \\ \vdots & & \vdots & & \vdots \\ x_{N1} - \bar{X}_1 & \cdots & x_{Np} - \bar{X}_p & \cdots & x_{NP} - \bar{X}_P \end{pmatrix}$$

La moyenne des colonnes de est égale à 0.

- Matrice de covariance des notes :

	Math	Phys	Fran	Angl
Math	0.8832099	0.53086420	0.9487654	0.32802469
Phys	0.5308642	0.40172840	0.4941975	0.01493827
Fran	0.9487654	0.49419753	1.3143210	0.58024691
Angl	0.3280247	0.01493827	0.5802469	1.05283951

- Inertie du nuage :**3.6520988**

DIAGONALISATION DE V

Réaliser l'ACP du nuage revient à diagonaliser la matrice V .

Rappel

La matrice V étant symétrique il existe une base orthonormale de vecteurs propres $u_1, \dots, u_p$ de V telle que

$$V = U \cdot D \cdot U^T,$$

où $U = [u_1, \dots, u_p]$ et D est une matrice diagonale dont les éléments $\lambda_1 > \dots > \lambda_p$ sont les valeurs propres de V .

Les axes de direction les vecteurs propres de V sont appelés les **axes principaux de X** .

PROPRIÉTÉ FONDAMENTALE DES AXES PRINCIPAUX

On peut démontrer que :

- Le premier axe principal maximise la variance empirique des données projetées sur cet axe. Cette variance vaut λ_1 (plus grande valeur propre de la matrice de covariance V).
- Le deuxième axe principal maximise la variance empirique qui n'est pas expliquée par le premier axe (on impose que les deux axes soient orthogonaux). Cette variance vaut λ_2 (la deuxième plus grande valeur propre de la matrice de covariance V). Et ainsi de suite...


RÉDUCTION DE DIMENSION

- Les vecteurs $u_1, \dots, u_P$ définissant les P axes principaux de la matrice X forment une base orthonormale de $\mathbb{R}^P$ et les coordonnées des N individus du nuage initial (centré) dans cette base sont

$$\tilde{X} = X^c U.$$

- Réduire à $k < P$ dimensions la matrice X revient à sélectionner les k premières colonnes de $\tilde{X}$.
- Se pose la question du choix du nombre de dimensions qui vont être suffisantes pour expliquer l'inertie totale.

EBOULIS DES VALEURS PROPRES



LES COMPOSANTES PRINCIPALES

Les composantes principales $CP_1, \dots, CP_P$ sont des **variables** qui sont des combinaisons linéaires des variables initiales définies par:

$$CP_p = \sum_{p'=1}^P u_{p'p} X_{\bullet p'}$$

où $U = [u_{p'p}]$ est la matrice des vecteurs propres de X .

- La variance de chaque composante principale CP_p est égale à la valeur propre associée λ_p .
- L'inertie du nuage est égale à la somme des valeurs propres (propriété algébrique des matrices) c'est à dire des variances des composantes principales :

$$\mathcal{J} = \sum_{p=1}^P \lambda_p$$


- Valeurs propres de la matrice de covariance des notes :

[1] 2.59228231 0.87965531 0.15653866 0.02362248

- Matrice U des vecteurs propres de la covariance V des notes :


	u1	u2	u3	u4
Math	0.5453880	-0.29315485	0.4066287	0.6717628
Phys	0.2902180	-0.38553424	0.5096121	-0.7123429
Fran	0.6891031	-0.08425841	-0.6985502	-0.1733927
Angl	0.3787643	0.87081807	0.2949173	-0.1060059

Par exemple : $CP_1 = 0.545 \times Math + 0.29 \times Phys + 0.689 \times Fran + 0.379 \times Angl.$



INTERPRÉTATION DE LA PROJECTION DES INDIVIDUS

- Le plan (CP_1, CP_2) correspond à 95.1% de l'inertie globale du nuage.
- Le point $(0,0)$ correspond à la moyenne du nuage (puisque toutes les variables ont été centrées).
- Le point le plus proche de $(0,0)$ correspond à l'individu le plus proche de la moyenne et le plus éloigné au plus éloigné de la moyenne.



APPROXIMATION DE LA DISTANCE ENTRE INDIVIDUS

- La distance de deux individus i, j dans $\mathbb{R}^P$ est

$$d(i, j) = \sqrt{\sum_{p=1}^P (x_{ip} - x_{jp})^2}.$$

- La distance de ces deux individus projetés dans (u_1, u_2) est

$$\tilde{d}(i, j) = \sqrt{(\tilde{x}_{i1} - \tilde{x}_{j1})^2 + (\tilde{x}_{i2} - \tilde{x}_{j2})^2}.$$

- La distance $\tilde{d}(i, j)$ donne une idée de la distance réelle entre i, j
- La qualité de représentation de l'individu n sur le plan est définie par

$$\cos^2(\theta) = \frac{\tilde{d}^2(n, 0)}{d^2(n, 0)}.$$

- Tableau des distances des individus dans $\mathbb{R}^4$:

	jean	alain	annie	monique	didier	andré	pierre	brigitte
alain	1.79							
annie	4.40	3.19						
monique	1.91	1.19	2.86					
didier	3.67	2.49	1.29	1.93				
andré	3.86	2.54	0.96	2.16	0.46			
pierre	2.03	1.73	4.55	1.91	3.61	3.78		
brigitte	4.00	2.36	3.57	2.74	2.92	2.83	2.65	
évelyne	4.22	3.29	1.11	2.60	1.00	1.12	4.42	3.87

- Tableau des distances des individus dans (CP_1, CP_2) :

	jean	alain	annie	monique	didier	andré	pierre	brigitte
alain	1.77							
annie	4.37	3.16						
monique	1.78	0.65	2.71					
didier	3.62	2.32	0.85	1.90				
andré	3.85	2.48	0.75	2.11	0.26			
pierre	1.85	1.30	4.43	1.90	3.58	3.72		
brigitte	4.00	2.30	3.54	2.69	2.88	2.83	2.57	
évelyne	4.15	3.12	0.52	2.60	0.96	1.00	4.42	3.83

QUALITÉ DE REPRÉSENTATION DES INDIVIDUS

La qualité de représentation d'un individu I_n sur un axe est mesurée par l'angle θ entre le vecteur $\overrightarrow{OI_n}$ et le vecteur $\overrightarrow{OJ_n}$ où J_n est son projeté sur l'axe considéré. La matrice suivante donne les valeurs de $\cos^2(\theta)$:

	Dim.1	Dim.2
jean	0.65569970	0.3291073536
alain	0.75634896	0.0002931929
annie	0.92222983	0.0033470361
monique	0.50810455	0.2964253882
didier	0.91134728	0.0004281002
andré	0.97573856	0.0159329547
pierre	0.92898513	0.0214004428
brigitte	0.06135987	0.9360435223
évelyne	0.87020103	0.0893377875


- Tableau des distances des individus dans $\mathbb{R}^4$:

	jean	alain	annie	monique	didier	andré	pierre	brigitte
alain	1.79							
annie	4.40	3.19						
monique	1.91	1.19	2.86					
didier	3.67	2.49	1.29	1.93				
andré	3.86	2.54	0.96	2.16	0.46			
pierre	2.03	1.73	4.55	1.91	3.61	3.78		
brigitte	4.00	2.36	3.57	2.74	2.92	2.83	2.65	
évelyne	4.22	3.29	1.11	2.60	1.00	1.12	4.42	3.87

- Tableau des distances des individus dans (CP_1, CP_2) :

	jean	alain	annie	monique	didier	andré	pierre	brigitte
alain	1.77							
annie	4.37	3.16						
monique	1.78	0.65	2.71					
didier	3.62	2.32	0.85	1.90				
andré	3.85	2.48	0.75	2.11	0.26			
pierre	1.85	1.30	4.43	1.90	3.58	3.72		
brigitte	4.00	2.30	3.54	2.69	2.88	2.83	2.57	
évelyne	4.15	3.12	0.52	2.60	0.96	1.00	4.42	3.83

	Dim.1	Dim.2
jean	0.65569970	0.3291073536
alain	0.75634896	0.0002931929
annie	0.92222983	0.0033470361
monique	0.50810455	0.2964253882
didier	0.91134728	0.0004281002
andré	0.97573856	0.0159329547
pierre	0.92898513	0.0214004428
brigitte	0.06135987	0.9360435223
évelyne	0.87020103	0.0893377875



CONTRIBUTION DES INDIVIDUS


La contribution de l'individu I_n à la composante principale q est définie par :

$$C_{nq} = \frac{\tilde{x}_{nq}^2}{N\lambda_q}.$$

	Dim.1	Dim.2
jean	18.618202	27.538488694
alain	5.032524	0.005748927
annie	18.482429	0.197674228
monique	1.621558	2.787819601
didier	6.528246	0.009037072
andré	8.285993	0.398728409
pierre	23.245597	1.578063456
brigitte	1.388100	62.402539168
évelyne	16.797351	5.081900446

c'est donc la proportion d'inertie de I_n dans l'inertie de l'axe.

CONTRIBUTION DES INDIVIDUS




CARACTÉRISATION DES COMPOSANTES PRINCIPALES

- Les composantes principales sont des combinaisons linéaires des variables initiales, donc on veut interpréter les projections des individus par rapport aux variables initiales.
- La coordonnée $\tilde{X}_{pq}$ de la variable $X_{\bullet p}$ sur l'axe principal CP_q est égale à

$$\frac{\text{cov}(X_{\bullet p}, CP_q)}{\sqrt{\text{var}(CP_q)}},$$

- avec par construction $\text{var}(CP_q) = \lambda_q$.

$$\text{Donc on a } \tilde{X}_{pq} = \sum_{p'=1}^P u_{p'q} \frac{\text{cov}(X_{\bullet p}, X_{\bullet p'})}{\sqrt{\lambda_q}}.$$



	Dim.1	Dim.2
Math	0.8781055	-0.27494976
Phys	0.4672673	-0.36159234
Fran	1.1094950	-0.07902591
Angl	0.6098320	0.81673975

APPROXIMATION DE LA COVARIANCE DES VARIABLES


La projection des variables permet d'obtenir une approximation des covariances entre ces variables :

	Math	Phys	Fran	Angl
Math	0.8466667	0.50972977	0.9959818	0.31093446
Phys	0.5097298	0.34908779	0.5470059	-0.01037226
Fran	0.9959818	0.54700594	1.2372242	0.61206196
Angl	0.3109345	-0.01037226	0.6120620	1.03895891

qui est proche de la matrice de covariance initiale :

	Math	Phys	Fran	Angl
Math	0.8832099	0.53086420	0.9487654	0.32802469
Phys	0.5308642	0.40172840	0.4941975	0.01493827
Fran	0.9487654	0.49419753	1.3143210	0.58024691
Angl	0.3280247	0.01493827	0.5802469	1.05283951

QUALITÉ DE REPRÉSENTATION DES VARIABLES



Qualité de représentation

	Dim.1	Dim.2
Math	0.8730307	0.085593892
Phys	0.5434985	0.325466218
Fran	0.9365894	0.004751575
Angl	0.3532306	0.633585482

Matrice de covariance sur données projetées

	Math	Phys	Fran	Angl
Math	0.8466667	0.50972977	0.9959818	0.31093446
Phys	0.5097298	0.34908779	0.5470059	-0.01037226
Fran	0.9959818	0.54700594	1.2372242	0.61206196
Angl	0.3109345	-0.01037226	0.6120620	1.03895891


Matrice de covariance sur données initiales

	Math	Phys	Fran	Angl
Math	0.8832099	0.53086420	0.9487654	0.32802469
Phys	0.5308642	0.40172840	0.4941975	0.01493827
Fran	0.9487654	0.49419753	1.3143210	0.58024691
Angl	0.3280247	0.01493827	0.5802469	1.05283951


CONTRIBUTION DES VARIABLES AUX AXES PRINCIPALES

- Contribution à la construction de l'axe

	Dim.1	Dim.2
Math	29.744805	8.5939765
Phys	8.422646	14.8636653
Fran	47.486307	0.7099479
Angl	14.346242	75.8324103



INTERPRÉTATION CONJOINTE



L'axe I discrimine beaucoup les élèves (71% de variance)


INTERPRÉTATION CONJOINTE

	Math	Phys	Fran	Angl
jean	9.1	11.1	10.7	15.1
alain	10.2	12.1	11.3	14.3
annie	11.6	13.2	13.6	15.6
monique	9.8	11.7	12.3	14.6
didier	11.2	12.2	13.5	14.9
andré	11.4	12.6	13.4	14.9
pierre	9.0	11.5	11.3	13.2
brigitte	10.9	12.9	12.2	12.4
évelyne	11.2	12.3	14.1	15.7
moyenne.	10.5.	12.2	12.5.	14.5

Coordonnées positives
sur l'axe I : élèves
globalement meilleurs
que la moyenne

Coordonnées
négatives sur l'axe I :
élèves globalement
inférieurs à la
moyenne

INTERPRÉTATION CONJOINTE




INTERPRÉTATION CONJOINTE

	Math	Phys	Fran	Angl
jean	9.1	11.1	10.7	15.1
alain	10.2	12.1	11.3	14.3
annie	11.6	13.2	13.6	15.6
monique	9.8	11.7	12.3	14.6
didier	11.2	12.2	13.5	14.9
andré	11.4	12.6	13.4	14.9
pierre	9.0	11.5	11.3	13.2
brigitte	10.9	12.9	12.2	12.4
évelyne	11.2	12.3	14.1	15.7
moyenne.	10.5	12.2	12.5	14.5

+ anglais,
- math physiques

- anglais,
+ math physiques

INTERPRÉTATION CONJOINTE



INTERPRÉTATION CONJOINTE GROUPEMENT D'INDIVIDUS


	Math	Phys	Fran	Angl
jean	9.1	11.1	10.7	15.1
alain	10.2	12.1	11.3	14.3
annie	11.6	13.2	13.6	15.6
monique	9.8	11.7	12.3	14.6
didier	11.2	12.2	13.5	14.9
andré	11.4	12.6	13.4	14.9
pierre	9.0	11.5	11.3	13.2
brigitte	10.9	12.9	12.2	12.4
évelyne	11.2	12.3	14.1	15.7
moyenne.	10.5	12.2	12.5	14.5

Groupe 1 : globalement au dessus de la moyenne dans la plupart des matières.


Groupe 2 : globalement inférieur à la moyenne dans la plupart des matières.

INTERPRÉTATION CONJOINTE

ATTENTION À NE PAS SUR-INTERPRÉTER



INTERPRÉTATION CONJOINTE ATTENTION À NE PAS SUR-INTERPRÉTER



ACP NORMÉE

- L'ACP est basée sur un tableau de données centré sur ces colonnes (c'est à dire que toutes les moyennes des colonnes valent 0).
- On peut aussi appliquer l'ACP sur un tableau standardisé c'est à dire dont les colonnes sont centrées et de variance 1. Cela revient à appliquer l'ACP sur le tableau Z tel que :

$$z_{np} = \frac{x_{np} - \bar{X}_{\cdot p}}{\sigma(X_{\cdot p})}.$$

- Lorsque le tableau Z est standardisé la matrice de covariance de Z est égale à la matrice de corrélation de X .

ACP NON NORMÉE VERSUS NORMÉE

- Réaliser une ACP non normée va favoriser les variables ayant la plus grande variance dans la construction des axes principaux.
→ lorsque les variables ont des dispersions similaires les résultats seront assez proches.
- Réaliser une ACP normée donne le même poids à chaque variable dans la construction des axes principaux.
→ lorsque les variables ont des unités différentes cette méthode permet de neutraliser leur effet.

- Matrice de corrélation des notes :

	Math	Phys	Fran	Angl
Math	1.0000000	0.89122059	0.8805949	0.34016803
Phys	0.8912206	1.00000000	0.6801169	0.02296958
Fran	0.8805949	0.68011693	1.0000000	0.49326583
Angl	0.3401680	0.02296958	0.4932658	1.00000000

ACP NON NORMÉE VERSUS ACP NORMÉE CAS DES NOTES

